

ModulA

Jana Obšteter

November 10, 2020

Contents

1	Osnove R-a	2
2	Osnovni podatkovni tipi in strukture	2
2.1	Podatkovni tipi	2
2.1.1	Cela števila	2
2.1.2	Realna števila	3
2.1.3	Znaki	3
2.1.4	Logični vektor	3
2.1.5	Manjkajoča vrednost	3
2.1.6	Prazen element	3
2.2	Podatkovne strukture	4
2.2.1	Vektor	4
2.2.2	Faktor	4
2.2.3	Seznam	4
2.2.4	Podatkovni okvir / tabela	5
2.2.5	Matrika	5
2.2.6	Polje	5
3	Osnovne operacije	6
3.1	Osnovni aritmetični operatorji	6
3.2	Primerjalni operatorji	6
3.3	“Operatorji” za znake	7
3.4	Osnovne vgrajene funkcije	7
4	Osnove dela z datotekami	8
4.1	Nastavitev delovnega imenika	8
4.2	Branje datotek	8
4.3	Lastnosti prebranih podatkov	8
4.4	Osnovne operacije na tabelah	9
4.5	Pisanje podatkov	10
5	Povzemanje podatkov	10
5.1	Združevanje podatkov s funkcijami paketa dplyr	11
6	Preurejanje podatkov	11
6.1	tidyr funkcije za preurejanje podatkov	12

1 Osnove R-a

V R-u lahko ukazno kodo pišemo direktno v konzolo ali v urejevalnik, pri čemer se koda vedno izvrši v konzoli.

```
# Seštejemo števili 3 + 5
```

Spremenljivkam vrednosti pripišemo z operatorjem `<-`, ki je značilen za programski jezik R, lahko pa uporabimo tudi `=`. Ime spremenljivke je poljubno in lahko vključuje velike in male črke, `.` in `/`. *Ne sme se začeti s številko ali* ter ne sme vključevati šumnikov.

```
# Spremenljivki stevilo pripišemo vrednosti 3
```

```
# Pokličemo spremenljivko stevilo
```

Vrstice, ki se pričnejo z `#` so komentarji in se ne izvršijo

```
# Nastavimo stevilo
```

```
# stevilo <- 3
```

R-funkcije so vključene v različne pakete oz. knjižnice. Nekatere knjižnice z osnovnimi funkcijami so v R naložene kot privzeto, ostale pa moramo namestiti. Knjižnice namestimo z ukazom `install.packages("imePaketa")`. Namestitev paketa je enkratna, ob vsakem zagonu R-a pa moramo želene knjižnice naložiti v delovni prostor z ukazom `library(imePaketa)`.

```
# Kot primer naložimo paket 'base', ki je kot privzet vključen v R
```

2 Osnovni podatkovni tipi in strukture

2.1 Podatkovni tipi

R razlikuje med različnimi podatkovnimi tipi. V nadaljevanju bomo ustvarili spremenljivko vsakega izmed tipov. Tip spremenljivke preverimo s funkcijo `class(spremenljivka)`.

2.1.1 Cela števila

```
# Ustvarimo spremenljivko "stevilo" z vrednostjo 10
```

```
# Izpišimo "stevilo"
```

```
# Preverimo tip spremenljivke
```

R cela števila ustvari kot tip `"numeric"` in ne `"integer"`. Če želimo, da je spremenljivka eksplicitno tip `"integer"`, jo moramo pretvoriti. Med podatkovnimi tipi pretvarjamo s funkcijo `as.podatkovniTip(vrednost/spremenljivka)`, v tem primeru `as.integer(vrednost)`.

```
# Ustvarimo spremenljivko "stevilo" z vrednostjo 10 kot "integer"
```

```
# Preverimo tip spremenljivke
```

Eksplicitno lahko tip `"integer"` ustvarimo tudi z dodatkom črke `"L"` na koncu celega števila.

```
# Direktno ustvarimo "integer" spremenljivko "stevilo" z vrednostjo 10
```

2.1.2 Realna števila

```
# Ustvarimo spremenljivko "realnoStevilo" z vrednostjo 3.52
# Izpišimo "realnoStevilo"
# Preverimo tip spremenljivke
```

2.1.3 Znaki

Znake R navaja v navednicah, pri čemer je lahko znak črkovni, številčni ali kombinacija obeh.

```
# Ustvarimo spremenljivko "beseda" z vrednostjo "jagoda"
# Izpišimo spremenljivko "beseda"
# Preverimo tip spremenljivke
```

2.1.4 Logični vektor

Logične vrednosti v R-u so TRUE in FALSE (velike črke).

```
# Ustvarimo spremenljivko "logicnaVrednost" z vrednostjo TRUE
# Izpišimo "logicnaVrednost"
# Preverimo tip spremenljivke
```

Z logičnimi vrednostmi lahko tudi računamo, pri čemer je vrednost TRUE vredna 1, vrednost FALSE pa 0.

```
# Sesštejmo vrednosti TRUE in TRUE
```

2.1.5 Manjkajoča vrednost

Manjkajoče vrednosti v R-u so predstavljene kot NA.

```
# Ustvarimo spremenljivko "manjkaVrednost" z manjkajočo vrednostjo
# Izpišimo "manjkaVrednost"
# Preverimo tip spremenljivke
```

2.1.6 Prazen element

Prazen element R predstavi kot NULL.

```
# Ustvarimo prazen element "prazenElement"
# Izpišimo "prazenElement"
# Preverimo tip spremenljivke
```

2.2 Podatkovne strukture

V R-u lahko ustvarimo različne podatkovne strukture. V nadaljevanju bomo ustvarili vsako izmed struktur.

2.2.1 Vektor

Vektor ustvarimo s funkcijo `c()`, v oklepaje navedemo vrednosti ločene z vejico - vektor(*vrednost1*, *vrednost2* ...). Vektor vključuje en podatkovni tip.

```
# Ustvarimo številski vektor "stevila" z vrednostmi 1, 10 in 100
# Izpišimo vektor
```

Vektor številskega zaporedja lahko ustvarimo tudi z navedbo razpona števil (začetek:konec).

```
# Ustvarimo številski vektor "meseči" s številskimi meseci 1 do 12
# Izpišimo vektor
```

Vektorje znakov prav tako ustvarimo s funkcijo `c()`, znotraj oklepajev navedemo znake ločene z vejico. Znake podamo znotraj narekovajev.

```
# Ustvarimo vektor znakov "letniCasi" z letnimi časi
# Izpišimo vektor
```

Elemente vektorjev izberemo z indeksom v oglatih oklepajih, `vektor[indeks]`.

```
# Izberimo drugi element vektorja "letniCasi"
```

2.2.2 Faktor

Faktorji so 'vektorji' kategoričnih spremenljivk. Vsebujejo določeno število vrednosti oz. ravni. Ustvarimo jih s funkcijo `factor()`. Znotraj oklepajev navedemo ravni ločene z vejico.

```
# Ustvarimo faktor "letniCasi_f" s ponovljenimi vrednostmi za letne čase
# c("pomlad", "pomlad", "poletje", "poletje", "jesen", "jesen", "zima", "zima")
# Izpišimo "letniCasi_f"
```

Ko je faktor ustvarjen, ne moremo dodajati oz. ustvariti novih ravni.

```
# Poskušajmo spremeniti drugi element faktorja letniCasi_f v novo raven "zjutraj"
# Ta operacija je nedovoljena, saj "zjutraj" ni ena izmed ravni faktorja (ne moremo ustvariti novih)
```

2.2.3 Seznam

Seznam ustvarimo s funkcijo `list()`, elemente seznama ločene z vejico navedemo znotraj oklepajev. Seznam lahko vključuje različne podatkovne tipe kot tudi strukture.

```
# Ustvarimo seznam "leto", ki vključuje vektorje
# "meseči" in "letniCasi" iz prejšnjega koraka in število 2020
# Izpišimo seznam "leto"
```

```
# Preverimo dolžino seznama "leto" s funkcijo length
```

Elemente seznama izberemo z indeksom v dvojnih oglatih oklepajih, `seznam[[indeks]]`.

```
# Izberemo prvi element seznama "leto"
```

Če ima element seznama podelemente (če je npr. vektor), le-te izberemo z indeksom z enojnih oglatih oklepajih, `seznam[element][podelement]`.

```
# Ker je prvi element vektor, izberimo še peti element znotraj tega
```

2.2.4 Podatkovni okvir / tabela

Podatkovni okvir oz. tabelo ustvarimo s funkcijo `data.frame()`. Znotraj oklepajev navedemo `imeStolpca = vrednosti` za poljubno ime stolpcev. Podatkovni okvir lahko v posameznih stolpcih vsebuje različne podatkovne tipe.

```
# Ustvarimo tabelo "povpTemp" z letnimi časi in povprečno temperature za vsakega izmed njih  
# Predpostavimo, da je povprečna temperatura pomladi je 18, poleti 24, jeseni 13 in pozimi 5
```

```
# Izpišimo tabelo
```

Elemente tabele izberemo z indeksom vrstice/stolpca v oglatih oklepajih, `tabela[indeksVrstice, indeksStolpca]`.

```
# Izberimo prvo vrednost v prvem stolpcu tabele "povpTemp"
```

```
# Izberimo prvo vrstico tabele "povpTemp"
```

```
# Izberimo prvi stolpec tabele "povpTemp"
```

Stolpce tabel lahko izberemo tudi po imenu z operatorjem `$`, `tabela$stolpec`.

```
# Izberimo stolpec <LetniCasi> v tabeli "povpTemp"
```

2.2.5 Matrika

Matriko ustvarimo s funkcijo `matrix()`, znotraj oklepajev navedemo vrednosti, število stolpcev in vrstic. Matrike ponavadi vsebujejo numerične spremenljivke, saj omogoča matrično računanje.

```
# Ustvarimo matriko "vrednosti" z vrednostmi 1:20, štirimi vrsticami in petimi stolpci
```

```
# Izpišimo matriko
```

Elemente matrike izberemo z indeksom vrstice/stolpca v oglatih oklepajih (enako kot tabele), `matrika[indeksVrstice, indeksStolpca]`.

```
# Izberimo element v drugi vrstici tretjega stolpca matrike vrednosti
```

2.2.6 Polje

Polje ustvarimo s funkcijo `array()`, v oklepaju navedemo vrednosti, vektor dimenzij in imena dimenzij (neobvezno).

```
# Ustvarimo polje povpTempLeto s povprečnimi letnimi temperaturami v
```

```
# letnih časih v dveh različnih letih.
```

```
# Povprečna temperatura je vektor vrednosti 18, 24, 13, 5, 15, 27, 12, 7; leti sta 2018 in 2019
```

```
# Dimenzije: x = letni čas (4), y = povprečna temperatura (1), z = leto (2)

# Izpišimo polje "povpTempLeto"
```

3 Osnovne operacije

3.1 Osnovni aritmetični operatorji

Osnovni aritmetični operatorji v R-u so + za seštevanje, - za odštevanje, * za množenje, / za deljenje. Osnovne računske operacije lahko apliciramo na števila ali vektorje (enakih dolžin).

```
# Ustvarimo spremenljivki "a" z vrednostjo 2 in "b" z vrednostjo 11.2

# Ustvarimo spremenljivko "vsota" kot vsoto a in b

# Ustvarimo spremenljivko "razlike" kot vsoto a in b

# Ustvarimo spremenljivko "zmnožek" kot vsoto a in b

# Ustvarimo spremenljivko "kvocient" kot vsoto a in b
```

Ponovimo vajo z vektorji.

```
# Ustvarimo vektorja "a" z vrednostmi c(1, 2, 3) in "b" z vrednostmi c(3.12, 5.44, 10)

# Ustvarimo spremenljivko "vsota" kot vsoto a in b

# Ustvarimo spremenljivko "razlike" kot vsoto a in b

# Ustvarimo spremenljivko "zmnožek" kot vsoto a in b

# Ustvarimo spremenljivko "kvocient" kot vsoto a in b
```

R ima posebej operator za ostanek pri deljenju %% , celoštevilsko deljenje %/% in množenje matrik %*%.

```
# Preverimo ostanek pri deljenju 10 / 3

# Preverimo celoštevilski kvocient deljenja 10 / 3

# Ustvarimo matriko m1 z vrednostmi 1:9 in tremi vrsticami
# ter matriko m2 z vrednostmi 9:18 in tremi vrsticami
```

3.2 Primerjalni operatorji

V R-u lahko uporabimo tudi operatorje primerjav, ki vrnejo logične vrednosti. Primerjamo lahko katerikoli podatkovni tip ali strukturo. Primerjalni operatorji so > za večje, < za manjše, == za določanje enakosti in != za določanje neenakosti. Primerjalni operatorji vrnejo logično vrednost.

```
# Ustvarimo spremenljivko a z vrednotjo 5

# Preverimo, ali je 5 večje od 3

# Preverimo, ali je 5 enako 3

# Preverimo, ali 5 ni enako 3

# Preverimo, ali vektor c(1, 2, 3) vsebuje 4
```

Operatorje primerjav lahko uporabimo tudi za druge podatkovne tipe. Logične vrednosti so interno zapisane kot 1 (TRUE) in 0 (FALSE), tako da jih lahko tudi seštevamo.

```
# Previdmo, koliko vrednosti a (5) je v vektorju vrednosti = c(1, 3, 5, 4, 5, 7)
```

3.3 “Operatorji” za znake

Za združevanje znakov ne moremo uporabiti enakih operacij kot za številske spremenljivke. Za združevanje znakov uporabimo funkcijo `paste()`, kjer v oklepajih navedemo spremenljivke za združevanje, s parametrom `sep` pa navedemo željeno ločilo.

```
# Združimo besedi Janez in Novak s presledkom
```

Lahko uporabimo tudi funkcijo `paste0()`, ki ima kot privzeto ločilo “”.

```
# Združimo besedi Janez in Novak brez ločila
```

3.4 Osnovne vgrajene funkcije

R vključuje kopico vgrajenih funkcij za najrazličnejše pogosto uporabljene operacije. Nekaj osnovnih funkcij vključuje `sum()` za vsoto, `mean()` za povprečje, `var()` za varianco, `sd()` za standardni odklon, `length()` za dolžino elementa, `min()` za minimalno vrednost, `max()` za maksimalno vrednosti in `print()` za izpis. Večina navedenih funkcij deluje na vektorjih, nekatere pa tudi na drugih elementih.

```
# Ustvarimo vektor "stevila" z vrednostmi 1:10
```

```
# Seštejmo elemente vektorja s funkcijo sum()
```

```
#Izračunajmo povprečje in varianco vektorja "stevila" s funkcijo mean() in var()
```

```
# Preverimo dolžino vektorja stevila s funkcijo length()
```

```
# Preverimo minimalno in maksimalno vrednost vektorja "stevila" s funkcijama min() in max()
```

Pri računskih operacijah lahko naletimo tudi na manjkajoče vrednosti, ki jih kot privzeto R ne odstrani.

```
# Ustvarimo vektor vrednosti <- c(1, 2, 3, 4, NA)
```

```
# Seštejmo vektor vrednosti
```

Funkcije vrnejo manjkajočo vrednosti, če element vsebuje manjkajoče vrednosti ne more izračunati. vsote ali povprečja. V pomoči za funkcije lahko preverimo, kako prilagoditi obnašanje funkcije. Funkcija `sum()` naprimer vključuje logični parameter `na.rm`, ki določi, ali naj bodo manjkajoče vrednosti odstranjene.

```
# Preverimo pomoč za funkcijo sum()
```

```
# Ponovno sštejmo vektor vrednosti  
# Ker želimo odstraniti manjkajočih vrednosti, nastavimo parameter na.rm na FALSE
```

4 Osnove dela z datotekami

4.1 Nastavitev delovnega imenika

Delovni imenik v R-u je privzeta pot za branje in pisanje datotek. V R-u lahko preverimo trenutni delovni imenik s funkcijo `getwd()`.

Delovni imenik lahko nastavimo s funkcijo `setwd()`.

Na primeru bomo pogledali, kako v R prebrati tabelo, izluščiti lastnosti podatkov, preurediti tabelo in zapisati rezultat.

4.2 Branje datotek

Različne tipe datotek v R preberemo z različnimi funkcijami oz. različnimi parametri. V nadaljevanje bomo v R prebrali .csv datoteko ter pregledali vsebino tabele. Ime datoteke je `ZivljenjskaDoba.csv`, ki vsebuje podatke zbrane s strani organizacija WHO o življenjski dobi (`ZivDoba`) v izbranih državah (`Country`). Datoteka vsebuje tudi podatke o statusu države (`Status`), Umrljivosti, zaužitem alkoholu v litrih (`Alkohol`), odstotek imuniziranih 1-letnikov na hepatitis B (`HepatitisB`), število primerov ošpic na 1000 prebivalcev (`Ospice`) in indeks telesne mase (`ITM`).

```
# Preberimo datoteko ZivljenjskaDoba_mali.csv
```

4.3 Lastnosti prebranih podatkov

Najprej preverimo, ali so podatki prebrani pravilno. Ponavadi pogledamo prvih par vrstic s funkcijo `head()`, zadnjih par s funkcijo `tail()` in pa strukturo podatkov s funkcijo `str()`.

```
# Preverimo prvih par vrstic prebrane tabele s funkcijo head()
```

```
# Preverimo zadnjih par vrstic prebrane tabele s funkcijo tail()
```

```
# Preverimo strukturo prebrane tabele s funkcijo str()
```

S funkcijami `as.podatkovniTip()` lahko spremenimo podatkovni tip stolpcev, npr. `as.factor()` ali `as.data.frame()`.

```
# Vidimo, da je leto kodirano kot številsko spremenljivka (integer).  
# S funkcijo as.factor() jo spremenimo v faktor (kategorično spremenljivko).
```

Preverimo lahko tudi število prebranih stolpcev in vrstic s funkcijama `ncol()` in `nrow()`.

```
# Preverimo število vrstic in število stolpcev
```

S funkcijo `colnames(objekt)[indeksStolpca]` lahko preimenujemo stolpce.

```
# Preimenujmo stolpec "Country" v "Drzava"
```

```
# Preverimo tabelo
```


Vrstice tabele izberemo z indeksom v oglatih oklepajih, `tabela[indeksVrstice,]`. Stolpce tabele lahko prav tako izberemo z indeksom v oglatih oklepajih `tabela[,indeksStolpca]` ali znakom `$` in imenom stolpca, `tabela$stolpec`. Če v indeksu ne navedemo številke stolpca (ali vrstice), R izbere vse stolpce (vrstice).

```
# Izberimo tretjo vrstico tabele zivDoba z indeksom
```

```
# Izberimo tretji stolpec tabele zivDoba z indeksom [vrstica, stolpec]
```

```
# Izberimo tretji stolpcev tabele zivDoba z imenom (Status)
```

S funkcijo `table()` preverimo zastopanost posamezne spremenljivke znotraj stolpcev, pri čemer je funkcija bolj uporabna za kategorične spremenljivke.

```
# Preverimo, koliko podatkov (vrstic) imamo po državi s funkcijo table()
```

Za preverjanje stolpcev v numeričnih stolpcev je bolje uporabiti funkcijo `summary()`. Ta vrne minimalno (in maksimalno) vrednost spremenljivke, prvi (in tretji) kvantil in povprečje.

```
# Preverimo vsebnost stolpca ZivDoba s funkcijo summary
```

Za preverjanje parametrov podatkov lahko uporabimo tudi funkcije kot npr. `mean()` za povprečje, `sd()` za standardni odklon, `var()` za varianco itd.

```
# Preverimo povprečje življenjske dobe preko vseh držav
```

```
# Preverimo varianco življenjske dobe
```

```
# Preverimo minimalno umrljivost v podatkih
```

```
# Preverimo maksimalno umrljivost v podatkih
```

4.4 Osnovne operacije na tabelah

V tabeli lahko uporabimo operatorje primerjav, da izberemo samo določene vrstice ali vrednosti.

```
# Izberimo vse vrstice tabele, v katerih je vrednost spremenljivke ZivDoba večja od 85
```

```
# Izberimo vse vrstice, v katerih je vrednost stolpca "Drzava" enaka "France"
```

Tabelam lahko tudi dodajamo in odstranjujemo vrstice in stolpce. Stolpce in vrstice odstranjujemo z znakom `-` (minus) ter navedbo indeksa.

```
# Odstranimo stolpec "Polio" z indeksom iz tabele zivDoba
```

```
# novo ustvarjeno tabelo poimenujemo zivDoba_nov
```

```
# Preverimo imena stolpcev nove tabele zivDoba_nov s funkcijo colnames()
```

Izbrane vrstice in/ali stolpce lahko tudi zapišemo v nov objekt oz. tabelo.

```
# Ustvarimo vektor 'ospiceFR', v katerega zberemo podatke o letu in pojavnosti ošpic v Franciji
```

```
# Preimenuj drugi stolpceviz 'Ospice' v 'ospiceFR'
```

```
# Ustvarimo vektor 'ospiceBR', v katerega zberemo podatke o letu in pojavnosti ošpic v Braziliji
```

```
# Preimenuj drugi stolpceviz 'Ospice' v 'ospiceBR'
```

```
# Ustvarimo vektor 'ospiceAU' in 'ospiceEG'
```

```
# Vanju zberemo podatke o pojavnosti ošpic v Austriji in Egiptu
```

Tabelam lahko tudi dodajamo vrstice ali stolpce z navedbo indeksa vrstice/stolpca ali imena stolpca ter vsebino, npr. `tabela$novStolpec <- vrednosti`.

```
# Ustvarimo nov stolpec "Celina" v tabeli zivDoba in mu pripišimo vrednost "Evropa"
```

```
# Preverimo tabelo
```

V tabelah lahko tudi spreminjamo vrednost. Stolpce, vrstica ali polja, katerim želimo spremeniti vrednost, lahko izberemo z indeksom, imenom stolpca ali pa operatorji primerjav (če želimo spremeniti le del vrednosti, ki ustrezajo nekemu pogoju).

```
# Vse države v tabeli zivDob ne ležijo v Evropi, in sicer "Egypt", "Brazil", "Chile" in "Peru"
# Naprej v vsrticah z vrednostjo "Egypt" spremenimo vrednost v stolpcu "Celina" na "Afrika"
```

```
"Brazil", "Chile" in "Peru" ležijo v Južni Ameriki
# Tem vrsticam spremenimo vrednost v stolpcu "Celina" na JuznaAmerika
```

```
# Preverimo zastopanost vrednosti v stolpcu "Celina"
```

4.5 Pisanje podatkov

S funkcijo `write.csv()` ali `write.table()` zapišemo podatke v datoteko.

```
# S funkcijo write.csv() zapišemo popravljeno tabelo zivDoba v datoteko
# ZivljenjskaDoba_popravljena.csv
# Shranimo podatke brez navednic in brez imena vrstic
```

5 Povzemanje podatkov

Pri prebranih podatkih nas ponavadi najprej zanimajo srednje vrednosti spremenljivk in razpršenost podatkov.

Vsoto lahko izračunamo s funkcijo `sum()`. Pri pregledovanju podatkov v tabelah lahko uporabimo tudi funkciji `rowSums()` in `colSums()`, ki vrnete vsoti vrstic ali stolpcev. Funkciji delujeta le na numeričnih podatkih, zato jih moramo naprej pretvoriti (`as.numeric()`) ali pa izbrati le numerične vrstice / stolpce.

```
# S funkcijo colSums() izračunajmo vsoto 4. do 30. stolpca tabele zivDoba
```

```
# V stolpcih z manjkajočimi vrednostmi funkcija ne more izračunati vsote in vrne NA vrednost.
# Obnašanje funkcije lahko prilagodimo z nastavitvijo parametra na.rm (na remove) na TRUE
```

Povprečje lahko izračunamo s funkcijo `mean()`. Enako kot pri vsoti lahko povprečja vrstic ion stolpcev tabele izračunamo s funkcijama `rowMeans()` in `colMeans()`. Funkciji enako delujeta le na numeričnih podatkih.

```
# S funkcijo colMeans() izračunajmo vsoto 4. do 30. stolpca tabele zivDoba.
# Funkcija naj odstrani manjajoče vrednosti
```

Kvantile lahko izračunamo s funkcijo `quantile()`. Privzeto R vrne vrednost za verjetnost 0, 0.25, 0.50, 0.75 in 1. S parametrom `probs` lahko določimo želene kvantile.

```
# S funkcijo quantile() izračunajmo kvantile z verjetnostjo
# 0.05 in 0.95 spremenljivke Umrljivost v tabeli zivDoba
```

Velikokrat želimo izračunati srednje vrednosti posameznih skupin oz. ravni neke spremenljivke. Za to lahko uporabimo funkcijo `aggregate()`, ki s poljubno funkcijo agregira podatke glede na podano formulo. Formulo navedemo v obliki `odvisnaSpremenljivka ~ neodvisnaSpremenljivka`.

```
# S funkcijo aggregate izračunajmo povprečno umrljivost v posamezni državi
# S funkcijo aggregate izračunajmo še standardni odklon umrljivost glede na status države in leto
```

5.1 Združevanje podatkov s funkcijami paketa dplyr

Funkcije paketa dplyr nam omogočajo bolj pregledno in uporabniku prijazno obdelavo podatkov.

S funkcijo `group_by()` lahko ustvarimo skupine v obstoječih tabelah. Sama funkcija podatkov ne spremeni, jih pa interno pripiše specificiranim skupinam.

```
# Najprej naložimo paket dplyr

# S funkcijo group_by() združimo podatke tabele zivDoba glede na leto in status
# ter jih shranimo v zivDoba_group

# Preverimo nastalo tabelo
```

S funkcijo `summarize()` lahko nato povzamemo podatke. Če so v podatkih že določene skupine, bo funkcija povzela po le-teh.

```
# S funkcijo summarize() izračunajmo povprečje in standardni odklon spremenljivk
# Umrljivost in Alkohol v zivDoba_group. Shranimo podatke v zivDoba_sum
```

Funkcije paketa dplyr lahko med sabo povežemo v “cevovodno” analizo z operatorjem `%>%`. Izhodni podatki prejšnje funkcije tako služijo kot vhodni podatki za naslednjo.

```
# V enem koraku v zivDoba ustvarimo skupine glede na status in leto
# ter izračunamo povprečje spremenljivke HepatitisB
```

6 Preurejanje podatkov

S funkcijo `cbind()` lahko povežemo vektorje ali tabele v novo tabelo. Pri tem morajo biti vektorji oz. tabele enakih dolžin.

```
# S funkcijo cbind() združimo zgoraj ustvarjene vektorje 'ospiceFR', 'ospiceAU' in 'ospiceEG'
# v novo tabelo 'ospice'

# Preverimo novonastalo tabelo
```

S funkcijo `merge()` lahko združujemo tabele na podlagi skupnega ključa. V obeh tabelah mora biti ime stolpca s ključem enako (parameter `by`). V nasprotnem primeru funkcijo navedemo ime ključa v vsaki izmed tabel s parametroma `by.x` in `by.y`, pri čemer je `x` prva tabela in `y` druga.

```
# S funkcijo merge() združimo zgoraj ustvarjene vektorje 'ospiceFR' in 'ospiceBR'
# na podlagi spremenljivke 'Leto' v novo tabelo 'ospiceMerged'

# Preverimo novonastalo tabelo
```

S funkcijo `melt()` iz paketa `reshape` lahko “vrtimo” tabele: spreminjamo razporeditev podatkov v stolpce in vrstice.

```
# Recimo, da želimo imeti en stolpec z vsemi vrednostmi za hepatitisB, polio in HIV za vse države,
# v drugem stolpcu pa bi imeli spremenljivko, za katero bolezen gre
# Takšno organizacijo podatkov ponavadi potrebujemo za grafično prikazovanje podatkov
```

```
# Najprej izberemo željene stolpce celotne tabele zivDoba - Drzava, Leto, HepatitisB, HIV in Polio
# Shranimo jih v tabelo bolezni

# Preverimo novonastalo tabelo

# S funkcijo melt() iz paketa reshape preuredimo tabelo,
# tako da sta naša ključa Leto in Drzava (stolpca bosta ostala nespremenjena)
# Novo nastalo tabelo poimenujemo bolezni_melt

# Preveimo novonastalo tabelo s funkcijo head()

#Preverimo vrednosti v stolpcu 'variable' tabele bolezni_melt
```

6.1 tidyr funkcije za preurejanje podatkov

tidyr je paket, ki vsebuje nabor funkcij za urejanje podatkov v R-u (<https://tidyr.tidyverse.org/reference/index.html>). Teži k “urejenosti” tabel in omogoča tudi podajanje podatkov med funkcijami z operatorjem %>%. Paket tidyr operira s podatkovni strukturo tibble (in ne data frame). Ta je preprostejša in omogoča manj operacij, s čimer pa omogoča hitrejšo odpravo napak in poenostavljenje kode. Paket naložimo z ukazom `library(tidyr)`.

Funkcija `pivot_longer()` opravlja enako nalogo kot funkcija `melt()`, ki smo jo uporabili zgoraj. Tabelo preuredi tako, da ima več vrstic in manj stolpcev oz. podaljša tabelo.

```
# Ponovimo vajo
# Sfunkcijo pivot_longer() iz paketa tidyr preuredimo tabelo bolezni (ustvarjena zgoraj),
# tako da zberemo vse vrednosti za stolpce HepatitisB, HIV in Polio v enem stolpcu
# Novo nastalo tabelo poimenujemo bolezni_longer
# Če tabele bolezni nimam več, zopet preberemo ZivljnjskaDoba.csv v R in ustvarimo
# bolezni <- zivDoba[, c("Drzava", "Leto", "HepatitisB", "HIV", "Polio")]

# Preverimo novonastalo tabelo
```

Obratna funkcija je `pivot_wider()`, ki ustvari tablo z več stolpci in manj vrsticami oz. razširi tabelo.

```
# S funkcijo pivot_wider() razširimo zgornjo tabelo bolezni_longer,
# da bodo podatki za vsako državo v svojem stolpcu

# Preverimo novonastalo tabelo
```

S funkcijo `separate()` združimo vrednosti dveh stolpcev. Enako lahko naredimo tudi s funkcijo `paste0()`. Nasprotje funkcije `unite()` je funkcija `separate()`.

```
# Združimo stolpca Drzava in Leto tabele bolezni z ločilom "_" v nov stolpec DrzavaLeto
```

Funkcija `expand()` prikaže vse kombinacije določenih spremenljivk v podatkih.

```
# S funkcijo expand() preverimo vse kombinacije spremenljivk Drzava in Leto
# v tabelo bolezni in rezultat shranimo v bolezni_kombo

# Preverimo število kombinacij

# Prikažemo zadnjih par vrstic tabele
```

S funkcijo `chop()` lahko podatke za določeno vrednost ali kombinacijo spremenljivk shranimo v en element - seznam.

```
# Uporabimo funkcijo chop(), da vse vrednosti za bolezni po letih shranimo  
# v eno spremenljivko glede na Drzavo. Rezultat shranimo v tabelo bolezni_chop.
```

```
# Preverimo rezultat
```

```
# Preverimo dimenzije vstopne in novonastale tabele
```

```
# Novonastala tabela je dimenzije
```

```
# Novonastala tabela vsebuje samo eno vrstico za vsako državo!
```

```
# Elementi tabele so sezname vektorjev
```

```
# Preverimo stolpec leto tabele bolezni_chop
```

```
# Preverimo stolpec Polio tabele bolezni_chop
```

```
# Elementi so sezname z vektorji za vsak nivo preostalih spremenljivk
```

Obratna funkcija je funkcija `unchop()`.

```
# Uporabimo funkcijo unchop() za razširitev podatkov tabele bolezni_chop
```

```
# Chopped tabelo lahko razširimo za posamezno ali vse spremenljivke
```

```
# Razširitev glede na vse spremenljivke povrne tabelo osnovno stanje
```

Funkcija `pack()` sesede stolpce v en stolpec-tabelo s skupnim imenom, ki ga določi uporabnik, in pod-imenom, ki je enako imenu vhodne spremenljivke.

```
# S funkcijo pack() sesedemo stolpce HepatitisB, HIV in Polio v stolpec-tabelo "Bolezni".
```

```
# Novonastalo tabelo poimenujemo bolezni_pack.
```

```
# Preverimo tabelo
```

```
# Ustvarili smo stolpec "Bolezen", ki ima eno vrstico za vsako državo in leto,
```

```
# element vrstice pa je tabela dimenzij 6x3
```

```
# Preverimo
```

V cevovod lahko združimo funkcije iz različnih paketov.

```
# V enem koraku tabelo bolezni preuredimo s funkcijo pivot_longer(),
```

```
# da bo imela vrednosti za vse bolezni v enem stolpcu (in imena bolezni v drugem),
```

```
# združimo po državi in bolezni in izračunajmo povprečje
```

```
# Ponovno ustvarimo tabelo bolezni in naložimo tidy, če jih nimamo več v delovnem okolju
```